OGVD - P2

Javier Santamaría González

Francisco Javier Morales Sánchez de Prados

> INTRODUCCIÓN

En esta segunda práctica, exploraremos el uso de la plataforma Azure de Microsoft para su aplicación en el área de Machine Learning y Big Data. Para ello, implementamos una serie de Notebooks de Jupyter (Python), así como un Pipeline de manejo de datos y entrenamiento de modelos para su posterior uso en inferencia.

En esta memoria, nos centraremos en el análisis de los costes derivados del uso de esta plataforma desglosándolo por recursos, así como en las herramientas de previsión de costes ofrecidas por Azure.

> ENLACES

Enlace al grupo de recursos (ml-rg):

https://portal.azure.com/#@upm365.onmicrosoft.com/resource/subscriptions/bd61684d -122e-4eab-82ae-04788cbc17d5/resourceGroups/ml-rg/overview

Enlace al área de trabajo de Azure Machine Learning (ml-workspace-jj):

https://ml.azure.com/?tid=6afea85d-c323-4270-b69d-

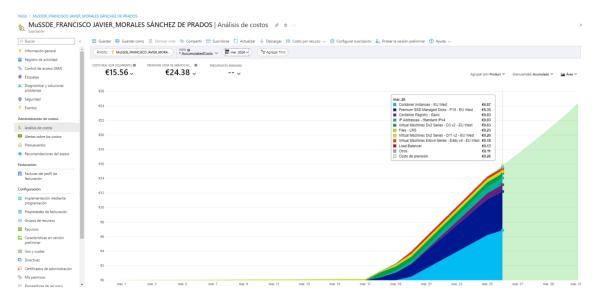
a4fb3927c254&wsid=/subscriptions/bd61684d-122e-4eab-82ae-

04788cbc17d5/resourceGroups/ml-

rg/providers/Microsoft.MachineLearningServices/workspaces/ml-workspace-jj

Enlace a la suscripción (MuSSDE_FRANCISCO JAVIER_MORALES SÁNCHEZ DE PRADOS): https://portal.azure.com/#@upm365.onmicrosoft.com/resource/subscriptions/bd61684d -122e-4eab-82ae-04788cbc17d5/overview

> RESUMEN DE COSTES



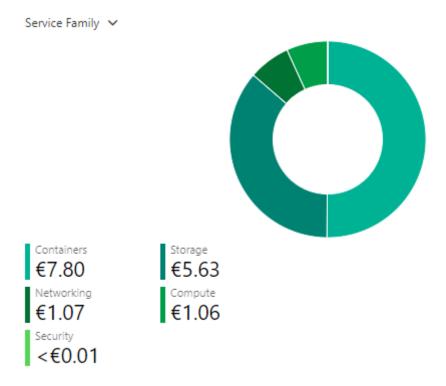
En la imagen, podemos observar varias cuestiones de forma rápida y sencilla en cuanto a costes:

1- Coste real: 15.56€

2- Previsión de costes hasta fin de mes: 24.38€

Así como una visión pormenorizada de qué **producto** se lleva cada porción del coste, con una mayor porción para las Container Instances y los Premium SSD Managed Disks respectivamente, es decir, contenedores y almacenamiento.

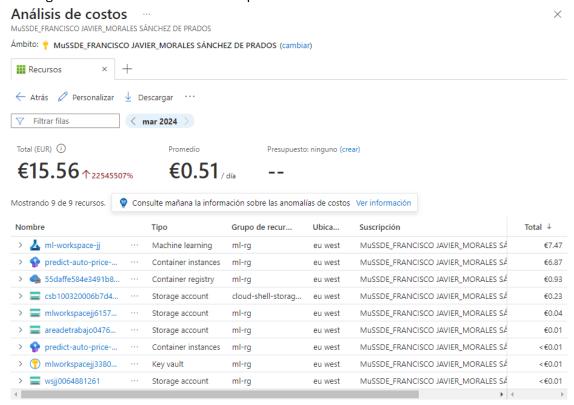
Obtengamos ahora una visión más generalizada de los costes por **familia de servicio**:



Como comentábamos en el párrafo anterior, los costes van, en este orden, para:

- 1- Contenedores, 7.80€.
- 2- Almacenamiento, 5.63€.
- 3- Cómputo y enrutamiento, 2.13€ agregados.

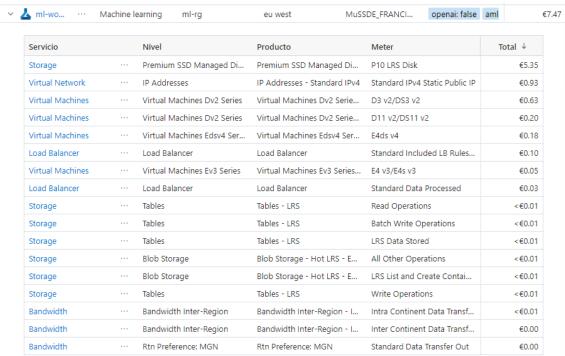
Obtengamos ahora una vista de coste por recursos:



Los recursos que más consumen, por orden, son:

1- ml-workspace-jj: 7.47€

De estos, se destinan:



- 5.35€ en almacenamiento, es decir, los Premium SSD Managed Disks comentados.

- 0.93€ en el establecimiento y manutención de una Red Virtual.
- 1.06€ agregados en máquinas virtuales.
- Resto repartido entre balanceadores de carga, operaciones de lectura y escritura, ancho de banda inter-regional etc.

2- predict-auto-price-...: 6.87€

De estos, se destinan: Predic... ... Container instances ml-rg Mussde Francis... createdbyamIstudic €6.87 eu west Total ↓ Container Instances €6.19 Container Instances Container Instances - EU W... Standard vCPU Duration Container Instances Container Instances - EU W... Standard Memory Duration Container Instances €0.68

- 6.19€ a tiempo de CPU virtual para instancias de contenedores.
- 0.68€ a tiempo de memoria estándar para instancias de contenedores.

¿A qué se debe todo este desglose de precios?

Dos pequeños notebooks.

- 1- Clasificador de botnets, completo.
- 2- Clasificador de setas, por terminar pero incluye descompresión y procesamiento de datos.

Varios flujos ejecutados definido en un pipeline a partir del experimento "autoprice", así como una API de inferencia disponible.

Este experimento "autoprice" ha consistido en el uso de pipelines de procesamiento en Azure para realizar una regresión sobre un dataset de ejemplo de precios/modelos de coches, con el fin de calcular el precio de un coche. Esto está disponible en el container "predict-auto-price" y ha consistido en:

- Cargar, limpiar y preparar los datos
- Hacer el split en train y test
- Entrenar y testear el modelo
- Desplegar el modelo en un endpoint (lo que permitiría su uso por API)
- Usar el modelo en dicho endpoint para calcular precios

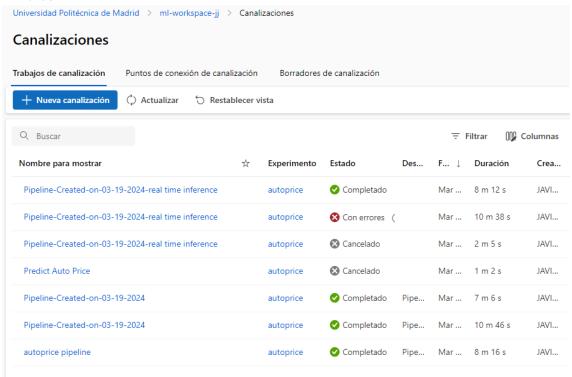
Como se ha podido ver anteriormente, gran parte del presupuesto se destina a **almacenamiento**.

El dataset de botnets es relativamente ligero, con menos de 5 MB para el conjunto de train y test. En cuanto al dataset para el clasificador de setas, este proyecto pretendía ser una red convolucional de neuronas, por lo que el dataset, compuesto de imágenes, es

significativamente más pesado, con unos 2GB de imágenes de setas comprimidos en un archivo .zip. El dataset del autoprice, al tratarse de datos en CSV y no imágenes, probablemente no supere los 300MB. Podemos afirmar con poco margen de error que los costes de almacenamiento derivan principalmente, por lo tanto, del coste de almacenar los 2GB de imágenes de setas.

A continuación, hablaremos de contenedores.

Estos se llevan la mayor parte del coste. En esta sección no incluimos el "tiempo de cómputo", que derivaría de la ejecución de los notebooks, sino que nos referimos a la ejecución de los pipelines para el autoprice, con un tiempo de ejecución medio de 8-10 minutos.



Aquí se encapsulan y dividen los costes de contenerización, tanto en tiempo de vCPU como de memoria estándar, así como probablemente la mayoría de costes de red virtual, ya que la inferencia se realiza mediante una API y además puede que Azure paralelice los entrenamientos pesados.

> REFERENCIAS

- El Moodle de la asignatura.
- Vídeo explicativo de creación de pipelines y uso de API de inferencia en Azure : https://www.youtube.com/watch?v=US1Mv00MCgo